



Data Anonymization

Prioridad	Alta
Encargado	Ángel Mauricio Ramírez Herrera [©] Guadalupe Paulina López Cuevas Diego Antonio García Padilla Kevin Ramirez Luna José Eduardo Viveros Escamilla [©] Cristian Chávez Guía ^F Fidel Alexander Bo
Estado	En curso
Fecha	@9 de noviembre de 2025
ID	20
Entregable	Select Data
Etiquetas	

[Contexto general](#)

[Políticas de acceso a los datos](#)

[Almacenamiento](#)

[Procesamiento](#)

[Acceso](#)

[Verificación de datos](#)

[Normativas](#)

[Anonimizar los datos](#)

[Técnica empleada para anonimizar los ID](#)

[Tabla de sustitución de Identificadores de Datos](#)

[Mecanismos y herramientas](#)

[Proceso Automatizado Durante la Carga de Datos](#)

[1 - Recepción de Datos Originales](#)

[2 - Detección de Identificadores](#)

[3 - Aplicación de Sustitución](#)

[4 - Almacenamiento Anonimizado](#)

[5 - Tabla de Correspondencia Segura](#)

[Triggers y Middlewares](#)

[Control de versiones](#)

Contexto general

Este reporte documenta el proceso de anonimización y manejo ético de los datasets del CAETEC utilizados en este proyecto de Inteligencia Artificial Avanzada para la Ciencia de Datos. Los datos provienen de fuentes internas del socio formador (CAETEC) e incluye registros individuales de vacas, producción diaria y eventos registrados por I@s veterinari@s.

El conjunto de datos incluye archivos como los siguientes, considerando a XXX como identificadores únicos de distintas vacas del CAETEC.:

- registro_ordeño.csv
- Todas la visitas a EO-PO XXX.csv (dataset de ordeño individual por vaca)
- Eventos de animales XXX.csv (dataset de ordeño individual por vaca)

Dentro de los datasets no existen datos personales ni información confidencial de personas.

Políticas de acceso a los datos

Almacenamiento

- Los datos se encuentran resguardados en un Google Drive institucional:  [Data Exploration & Preparation Archivos csv](#)
- El acceso a este repositorio requiere autorización previa de un miembro del equipo Vacas Saturno Saturnitas.
- No se permite el almacenamiento de los datos en dispositivos personales que no cuenten con cifrado.

Procesamiento

- El procesamiento de los datos está permitido únicamente en entornos de desarrollo locales y privados, o en notebooks seguros a los que solo puedan acceder las personas autorizadas por el equipo.

Acceso

- El acceso a los datos será concedido exclusivamente a personas verificadas dentro del espacio de trabajo en Notion o Google Drive, administrado por los miembros del equipo.

Verificación de datos

Debido al tipo de solución que el proyecto propone, se decidió ir en busca de datos adicionales para la evaluación de la factibilidad de la propuesta generada. Para esto los datos fueron recopilados de la maquina de ordeño DELAVAL, donde la doctora nos proporciono los datos tal cual como salen de la maquila. Debido a esto los datos proporcionados cuentan con alguno de los siguientes atributos :

- Número de vaca
- Edad en días
- Padre de la Madre - Semen
- Fecha de nacimiento
- Edad (a:mm)
- Padre de toro progenitor, ID/NRO de toro

Normativas

<https://docs.google.com/document/d/1ZKq67SZJSEGS7omckxj90d4jJqqnMfqJ4R0wRJnb7iU/edit?usp=sharing>

<https://docs.google.com/document/d/1qbb7-dDIE3FZyWesm9ZWfNBHG-96Oyup6J8B9V54iKU/edit?usp=sharing>

<https://docs.google.com/document/d/1SKFHXLrvShqgfScEOCDuYAZQaKlqgBRcINX-uMVDROs/edit?usp=sharing>

https://docs.google.com/document/d/166WqcMwUNFL9DK_MkGf-b3Cm0HZxQkOGgJoWVLaUpL8/edit?usp=sharing

<https://docs.google.com/document/d/1KIXMR71h-1NnwKKzIhsW-2DW-49aqH2DcRVjx3bQ4Zo/edit?tab=t.0>

<https://docs.google.com/document/d/1lXkWIvJuum8CjaTH2FekHlp6frs0SoMkAJoB2k2Cm5k/edit?usp=sharing>

<https://docs.google.com/document/d/1mwpsodJF14wRMDMEI3j6dzjkmizkpD0GUhyoqGaYpxU/edit?usp=sharing>

Anonimizar los datos

Para este enfoque, vamos a anonimizar los datos de una forma básica debido a que no hay información sensible de personas que necesite de técnicas avanzadas para proteger los datos.

La anonimización del ID de las vacas es importante cuando los datos son utilizados con fines de análisis, investigación o desarrollo de modelos, ya que permite proteger la identidad del animal sin comprometer la trazabilidad obligatoria establecida por la **NOM-001** que se puede encontrar en este documento.

Si bien la identificación individual del ganado es un requisito legal para garantizar el control sanitario, la trazabilidad y la prevención de riesgos como zoonosis, fraude o pérdida, en entornos de análisis internos o académicos no es necesario conservar identificadores reales.

Por ello, al anonimizar los ID, se evita exponer información sensible del sistema productivo o de los registros oficiales, manteniendo la confidencialidad de la fuente sin afectar la calidad del estudio.

Técnica empleada para anonimizar los ID

Para anonimizar los datos, utilizaremos la técnica de sustitución, esta técnica permite sustituir el contenido de una columna de una base de datos por datos procedentes de una lista predefinida de valores ficticios, de modo que la información no pueda rastrearse hasta un individuo identificable. Esta técnica tiene la ventaja de mantener intacta la integridad de la información original. <https://www.inext.se/elementor-7768/>

Al anonimizar los ID, se protege la información sensible del sistema productivo y de los registros oficiales, manteniendo la confidencialidad de la fuente sin afectar la calidad del estudio. Esta práctica permite cumplir con los objetivos de investigación mientras se resguarda la privacidad de los datos operacionales del rancho.

Para anonimizar los datos se utiliza la técnica de sustitución, que consiste en reemplazar el contenido de una columna de la base de datos con valores ficticios predefinidos. Esta técnica garantiza que:

- La información no puede rastrearse hasta un individuo identificable
- Se mantiene intacta la integridad referencial de los datos
- Las relaciones entre registros permanecen consistentes
- Los análisis estadísticos mantienen su validez

Tabla de sustitución de Identificadores de Datos

Carpeta de los archivos de las vacas:

https://drive.google.com/drive/u/1/folders/1JdYCPrt_OQrd2l1m_7gM1w3yCHedPI86

Identificador Original	Identificador Ficticio
1213	0001
1216	0002
1225	0003
1226	0004
1236	0005
1239	0006
1493	0007
1497	0008
1510	0009
1511	0010
1514	0011
1517	0012
1552	0013
1575	0014
1590	0015
2078	0016
2107	0017
2109	0018
2119	0019
2128	0020
2150	0021
5767	0022
6062	0023
6070	0024
6131	0025
6134	0026
6164	0027
6184	0028
6248	0029

8703	0030
8710	0031
8712	0032
8715	0033
8729	0034
8738	0035
8742	0036
8744	0037
8749	0038
8756	0039
8764	0040
8768	0041
8780	0042
8782	0043
8783	0044

Mecanismos y herramientas

La aplicación web que se desarrollará incorporará mecanismos automatizados de anonimización que transforman los datos sensibles en el momento de su carga, asegurando que ninguna información identificable quede expuesta en la base de datos operacional ni en las interfaces de usuario. Este documento explica cómo funcionan estos mecanismos de protección integrados en el flujo de ingesta de datos.

Proceso Automatizado Durante la Carga de Datos

Cuando un usuario carga datos crudos a la aplicación web, el sistema ejecuta automáticamente el siguiente flujo:

1 - Recepción de Datos Originales

El usuario importa archivos (CSV, Excel) o ingresa datos mediante formularios. Los datos llegan en su forma original conteniendo los identificadores reales de las vacas.

2 - Detección de Identificadores

El sistema identifica automáticamente las columnas que contienen IDs de vacas mediante el análisis de nombres de columna y formatos de datos.

3 - Aplicación de Sustitución

Los identificadores originales se reemplazan automáticamente por sus correspondientes identificadores ficticios según la tabla de mapeo predefinida.

4 - Almacenamiento Anonimizado

Los datos transformados se almacenan en la base de datos PostgreSQL. Únicamente los identificadores ficticios quedan accesibles en el sistema operacional y en las interfaces de usuario para los roles que no sean administradores ni colaboradores.

5 - Tabla de Correspondencia Segura

La tabla de mapeo (ID original al ID ficticio) se almacena de forma separada y con acceso restringido, permitiendo la trazabilidad solo cuando sea absolutamente necesario y autorizado.

Triggers y Middlewares

El sistema de auditoría de doble capa (triggers de PostgreSQL + middleware de aplicación) asegura que todos los accesos a datos queden registrados, proporcionando trazabilidad completa mientras se protege la confidencialidad de la información del rancho.

Control de versiones

Control de Versiones

Aa Nombre	≡ Cambios	👤 Personas	📅 Última modificación
<u>v1.0</u>	Primera versión	👤 Ángel Mauricio Ramírez Herrera 🗿 Diego Antonio García Padilla 🕒 Guadalupe Paulina López Cuevas	@9 de noviembre de 2025